



Process data with **SQL** in Apache Kafka

Mohammad Fozouni (Ph.D.)

MLSECOPS IN ACTION COURSE



ksqlDB



Compute

Kafka



Storage



- **ksqlDB** is a streaming SQL engine for Apache Kafka that allows you to process and analyze real-time data streams using SQL-like queries.

- **ksqlDB** is a streaming SQL engine for Apache Kafka that allows you to process and analyze real-time data streams using SQL-like queries.
- When you execute a ksqlDB command, ksqlDB internally **translates** these commands into equivalent Kafka Streams operations.

Stream vs. Table

STREAM (in ksqlDB)



STREAM (in ksqlDB)

Each event is processed as it arrives.
Result is another stream of events.



- Represents an unbounded sequence of events
- Order and time matter
- Duplicates allowed
- Use for real-time event processing

TABLE (in ksqlDB)





TABLE (in ksqlDB)

Key	Latest Value
A	100
B	250
C	75
...	...

Keeps the latest
value per key.
New events update
the table.



- Represents the latest state by key
- Only the most recent value is kept
- Updates overwrite previous values
- Use for aggregations, joins, lookups



Change Log Topic = A Kafka topic that records how the current state of a ksqIDB Table changes over time.

In the next two videos

1

ksqlDB

Producer


CSV files

JSON files

Avro files (Schema Registry)

Create Table and Stream

Consumer



ksqlDB

data poisoning defense

آیا مهاجمان در حال کرم ریزی هستند؟
ما قصد داریم دیتاهای بد یا دستکاری
شده رو در این مرحله گیر بندازیم.



kafka
Kafka Topic:
enriched_features

1) ENRICHED_FEATURES STREAM

Raw enriched feature stream



2) INVALID_FEATURE_ALERTS STREAM

Range / schema
validation guardrail



3) AMOUNT_STATS_5MIN TABLE

Rolling per-category
baseline stats
(5-minute windows)



4) VELOCITY_ALERTS TABLE

Velocity (transaction
burst) detection per card
(1-minute windows)



5) SECURITY_ALERTS STREAM

Unified security
alerts (from invalid
range alerts)



مهاجمان با ارسال حجم عظیمی از ورودی‌ها
قصد دارند که بفهمند آستانه‌ی مدل
تشخیصی ما چه عددی است.

adversarial probing

Materialized Windowed Tables (stateful)

2) INVALID_FEATURE_ALERTS
STREAM

3) AMOUNT_STATS_5MIN
TABLE

4) VELOCITY_ALERTS
TABLE

5) SECURITY_ALERTS
STREAM

هر تراکنش که در قواعد خاصی صدق
نمی‌کرد، فلگ خواهد شد

برای هر بیزینسی، هر 5 دقیقه یک میانگین می‌گیریم. برخی
بیزینس‌ها بالا و برخی پائین هستند.

هر کارت در یک بازه 1 دقیقه‌ای اگر بیش از 10
تراکنش انجام دهد، فلگ خواهد شد.

این استریم در اینجا زائد است. تنها برای اینکه در
آینده یک استریم واحد جهت دریافت موارد ممنوعه
داشته باشیم، آنرا تعریف می‌کنیم.



با کافکا کل اکوسیستم مهندسی داده را
می‌توان مدیریت کرد 🧠

با کافکا کل اکوسیستم مهندسی داده را می‌توان مدیریت کرد 🧠

Event-driven applications and microservices

Kafka Streams IN ACTION


SECOND EDITION

Bill Bejeck

Foreword by Jun Rao

 MANNING





دقت کنید که تاکید من روی ksqlDB نیست. هر
تکنولوژی که خواستید را انتخاب کنید. ممکن
است شخصی Flink SQL را انتخاب نماید. **فقط به**
کلیت کار و منظور من دقت کنید.

In this session we'll use
Confluent Community Edition
NOT Apache Kafka 🕶️

In this session we'll use
Confluent Community Edition
NOT Apache Kafka 🕶️

Confluent's packaging includes Kafka plus additional tooling
(ksqlDB, Schema Registry, connectors, etc.)

Coding Time

